

UERJ – INSTITUTO DE QUÍMICA
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA QUÍMICA
TÓPICOS ESPECIAIS EM ENG. QUÍMICA: APRENDIZADO DE MÁQUINA

Capítulo 6: Aprendizado Supervisionado Parte I

Lista de Exercícios: Use a linguagem R ou Python (livre escolha)

1ª. Questão: Valor 4,5 pontos

Use o conjunto de dados Breast Cancer Wisconsin (Diagnostic), disponível no repositório UCI Machine Learning:

Página do conjunto de dados: [Breast Cancer Wisconsin \(Diagnostic\) — UCI](#)

Download direto (arquivo .zip): [breast+cancer+wisconsin+diagnostic.zip](#)

O arquivo wdbc.data não possui linha de cabeçalho; os nomes das variáveis constam no arquivo wdbc.names, incluído no mesmo download. Faça a importação, remova a coluna de identificação (id) e mantenha a variável diagnosis como classe a ser predita.

- a) Aplique a normalização min-max às variáveis preditoras. (0,5 ponto)
- b) Crie os conjuntos de treinamento e de teste com, respectivamente, 469 e 100 instâncias. Compare a divisão posicional — as 469 primeiras linhas para treinamento e as 100 últimas para teste — com uma divisão aleatória estratificada pela variável diagnosis. Observe que, na divisão posicional, a proporção de casos malignos é de 40,3% no conjunto de treinamento e de apenas 23,0% no conjunto de teste, em comparação com 37,3% no conjunto completo. Justifique qual das duas partições é mais apropriada. (1,0 ponto)
- c) Empregue o algoritmo k-NN para criar o modelo. (0,5 ponto)
- d) Avalie o desempenho do modelo no conjunto de teste. (0,75 ponto)
- e) Aplique a padronização às variáveis e repita os itens anteriores. (0,75 ponto)
- f) Teste os valores de k para k = 1, 5, 11, 21 e 27. O que se pode concluir? (1,0 ponto)

2ª. Questão: Valor 5,5 pontos

Use o conjunto de dados Credit (credit.csv). Os dados de empréstimos são da Alemanha antes da adoção do Euro como moeda.

Download direto do arquivo: [credit.csv](#)

Utilize o endereço acima. O endereço da página do GitHub (github.com/.../blob/...) retorna a página HTML, não o arquivo CSV.

O arquivo contém 1.000 registros e 21 variáveis, sem valores ausentes. A variável-alvo default vem codificada como 1 e 2 (700 e 300 registros, respectivamente); converta-a em fator antes de treinar o modelo.

- a) Adote a semente aleatória (9829) como referência para comparação dos resultados. Observe que amostras obtidas com linguagens ou funções de amostragem distintas não coincidirão entre si. (0,5 ponto)
- b) Faça uma amostragem aleatória para criar um conjunto de treinamento com 900 instâncias. (0,5 ponto)
- c) Empregue o algoritmo C5.0 no conjunto de treinamento e avalie o seu desempenho no conjunto de teste. (1,5 ponto)
- d) Quais são os preditores mais importantes para a tarefa de classificação? (1,0 ponto)
- e) Este algoritmo permite aplicar boosting (aumentando o número de iterações) para reduzir a taxa de erro. Sugere-se adotar o parâmetro trials igual a 10. Faça uma reavaliação do modelo após esta etapa. O que se pode concluir? (2,0 pontos)

Observação: o algoritmo C5.0 é implementado no pacote C50 do R e não possui equivalente nativo no scikit-learn. Em Python, utilize uma árvore de decisão com boosting — por exemplo, AdaBoost ou Gradient Boosting sobre DecisionTreeClassifier — e indique, em sua resposta, a implementação adotada.