

UERJ – INSTITUTO DE QUÍMICA
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA QUÍMICA
TÓPICOS ESPECIAIS EM ENG. QUÍMICA: APRENDIZADO DE MÁQUINA

Capítulo 7: Aprendizado Supervisionado Parte II

Lista de Exercícios: Use a linguagem R ou Python (livre escolha)

1ª. Questão: Valor 10,0 pontos

Considere as informações abaixo a respeito do conjunto de dados (Tecator):

O Tecator Infratec Food and Feed Analyzer foi utilizado para obter o espectro de infravermelho próximo de 215 amostras de carne finamente picada, no intervalo de 850 a 1050 nm, correspondente à absorvância medida em 100 comprimentos de onda. Para cada amostra, os químicos analíticos determinaram as percentagens de água, gordura e proteína.

O conjunto está disponível no pacote caret do R, sob o nome tecator:

[Documentação de caret::tecator](#)

Ao carregá-lo, obtêm-se dois objetos: a matriz `absorp`, com os valores de absorvância das 215 amostras nos 100 comprimentos de onda, e a matriz `endpoints`, cujas colunas 1 a 3 contêm, respectivamente, as percentagens de água, gordura e proteína.

Os dados originais encontram-se no repositório StatLib da Carnegie Mellon University: lib.stat.cmu.edu/datasets/tecator

- a) Divida o conjunto em treinamento (80%) e teste (20%). Escolha a metodologia para realizar esta partição e justifique o seu emprego. (1,0 ponto)
- b) Proceda ao pré-processamento dos dados, se adequado, e justifique a metodologia escolhida. Observe que os 100 comprimentos de onda são fortemente correlacionados entre si. (1,5 ponto)
- c) Construa os modelos de regressão usando os algoritmos: MLR, PCR, PLS, Lasso, Ridge, Elastic Net e MARS para prever o teor de proteína na carne. (4,0 pontos)
- d) Para aqueles modelos de regressão que necessitam do ajuste dos hiperparâmetros, quais os valores ótimos dos hiperparâmetros? (2,0 pontos)
- e) Qual o modelo de regressão que tem a melhor capacidade preditiva? (1,5 ponto)

Observação: o algoritmo MARS é implementado no pacote earth do R. O scikit-learn não oferece implementação nativa; em Python, utilize um pacote específico de sua escolha, indicando-o na resposta.