

UERJ – INSTITUTO DE QUÍMICA
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA QUÍMICA
TÓPICOS ESPECIAIS EM ENG. QUÍMICA: APRENDIZADO DE MÁQUINA

Capítulo 8: Aprendizado Supervisionado Parte III

Lista de Exercícios: Use a linguagem R ou Python (livre escolha)

1ª. Questão: Valor 5,0 pontos

Considere as informações abaixo a respeito do conjunto de dados (Tecator):

O Tecator Infratec Food and Feed Analyzer foi utilizado para obter o espectro de infravermelho próximo de 215 amostras de carne finamente picada, no intervalo de 850 a 1050 nm, correspondente à absorvância medida em 100 comprimentos de onda. Para cada amostra, os químicos analíticos determinaram as percentagens de água, gordura e proteína.

O conjunto está disponível no pacote caret do R, sob o nome tecator:

[Documentação de caret::tecator](#)

Ao carregá-lo, obtêm-se dois objetos: a matriz `absorp`, com os valores de absorvância das 215 amostras em 100 comprimentos de onda, e a matriz `endpoints`, cujas colunas 1 a 3 contêm, respectivamente, as percentagens de água, gordura e proteína.

Os dados originais encontram-se no repositório StatLib da Carnegie Mellon University: lib.stat.cmu.edu/datasets/tecator

- a) Divida o conjunto em treinamento (80%) e teste (20%). Escolha a metodologia para realizar esta partição e justifique o seu emprego. (0,75 ponto)
- b) Proceda ao pré-processamento dos dados, se adequado, e justifique a metodologia escolhida. (0,75 ponto)
- c) Construa modelos de regressão usando os algoritmos SVM, k-NN e ANN para prever o teor de proteína na carne. Como o algoritmo ANN é sensível a preditores altamente correlacionados, sugere-se empregar o PCA como método de redução de dimensionalidade para obter novos preditores não correlacionados antes do uso da ANN. (2,5 pontos)
- d) Qual é o modelo de regressão com a melhor capacidade preditiva? (1,0 ponto)

2ª. Questão: Valor 5,0 pontos

Considere as informações a seguir sobre o conjunto de dados (ChemicalManufacturingProcess).

Este conjunto de dados contém informações sobre um processo de fabricação química, cujo objetivo é compreender a relação entre o processo e o rendimento do produto final. A matéria-prima, neste processo, passa por uma sequência de 27 etapas para gerar o produto farmacêutico final. O material inicial é gerado a partir de uma unidade biológica e apresenta uma variedade de qualidades e características. O objetivo deste projeto era desenvolver um modelo para prever o rendimento percentual do processo de fabricação.

O conjunto de dados consiste em 176 amostras de material biológico, para as quais foram medidas 57 características. Das 57 características, houve 12 medições do material biológico inicial e 45 do processo de fabricação. As variáveis do processo incluíam medições de temperatura, tempo de secagem e de lavagem, e concentrações de subprodutos em várias etapas. Algumas medições do processo podem ser controladas, enquanto outras são observadas. Os preditores são contínuos, de contagem, categóricos; alguns são correlacionados e alguns contêm valores ausentes. As amostras não são independentes porque os conjuntos de amostras vêm do mesmo lote de material biológico inicial.

Documentação do conjunto de dados: [ChemicalManufacturingProcess](#)

O conjunto é fornecido pelo pacote AppliedPredictiveModeling do R como um único data frame denominado ChemicalManufacturingProcess, com a coluna Yield (rendimento percentual) e 57 preditores, nomeados BiologicalMaterial01 a BiologicalMaterial12 e ManufacturingProcess01 a ManufacturingProcess45. Os objetos processPredictors e yield citados na literatura não são fornecidos pelo pacote: devem ser construídos a partir desse data frame, separando a primeira coluna das demais.

- a) Divida o conjunto em treinamento (80%) e teste (20%). Escolha a metodologia para realizar esta partição e justifique o seu emprego. (0,5 ponto)
- b) Proceda ao pré-processamento dos dados, tratando os valores ausentes presentes nos preditores, e justifique a metodologia escolhida. (1,0 ponto)

- c) Construa os modelos de regressão usando os algoritmos: Random Forest e Extreme Gradient Boosting para a predição do rendimento do processo. (2,0 pontos)
- d) Qual o modelo de regressão que tem a melhor capacidade preditiva? (0,75 ponto)
- e) Quais os preditores mais importantes nos modelos de regressão? (0,75 ponto)